

Exploratory Data Analysis — EDA

Antes de criar qualquer modelo, precisamos primeiro **entender os dados**. A Análise Exploratória de Dados (EDA) serve exatamente para isso: investigar como as variáveis se comportam, identificar padrões, relações, grupos, valores incomuns, dados ausentes e possíveis problemas de qualidade.

Nesta treinamento, cada gráfico será tratado como uma **ferramenta para responder uma pergunta**. O objetivo não é decorar nomes de gráficos, mas compreender **quando usar cada visualização, o que observar e quais conclusões não podemos tirar apenas olhando para ela**.

Ao final, a ideia é que você consiga receber uma base desconhecida e começar a investigá-la de forma organizada antes de partir para Machine Learning.

OBSERVAÇÕES SIMULADAS

2.000

Clientes fictícios usados para treinamento.

VARIÁVEIS

13

Numéricas, categóricas e temporais.

OBJETIVO

Investigar

Encontrar padrões antes de modelar.

✦ Todos os dados deste treinamento são simulados. Eles foram construídos propositalmente para demonstrar os diferentes conceitos de EDA.

SEÇÃO 01

O que é EDA?

EDA — Exploratory Data Analysis é o processo de investigar os dados antes de construir conclusões ou modelos.

? Pergunta

Se eu receber uma base que nunca vi antes, o que deveria descobrir antes de tentar Machine Learning?

Estrutura

ENTENDER O QUE EXISTE NA BASE

Antes de interpretar qualquer comportamento, precisamos saber **o que existe na base**: quantidade de linhas, quantidade de colunas, tipos de dados, unidades, identificadores e significado de cada variável. Uma coluna chamada `valor`, por exemplo, não é útil se não soubermos se representa reais, unidades vendidas ou uma pontuação.

Comportamento

ENTENDER COMO OS DADOS SE ORGANIZAM

Depois entendemos **como os dados se comportam**: onde se concentram, quanto variam, se existem assimetrias, grupos, tendências ou relações entre variáveis. É aqui que os gráficos ajudam a transformar milhares de linhas em padrões visuais mais fáceis de perceber.

Problemas

ENCONTRAR O QUE PODE DISTORCER A ANÁLISE

Finalmente procuramos sinais de **qualidade ou inconsistência**: valores ausentes, duplicidades, categorias inesperadas, valores impossíveis e outliers. Esses pontos podem mudar completamente uma análise ou prejudicar um modelo se passarem despercebidos.

Ideia principal

EDA não é produzir uma coleção de gráficos. EDA é usar estatística e visualização para responder perguntas.

SEÇÃO 02

Antes do gráfico: que tipo de variável eu tenho?

? Pergunta

Por que não podemos simplesmente escolher qualquer gráfico?

Porque cada tipo de dado permite perguntas diferentes. Em uma variável numérica podemos calcular distância, média e dispersão. Em uma variável categórica, como região ou canal, esses cálculos não fazem sentido da mesma forma. Já em datas, a ordem temporal é parte fundamental da informação.

Antes de escolher o gráfico, identifique **o tipo da variável** e depois defina **qual pergunta deseja responder**. Essa combinação normalmente aponta para uma pequena família de visualizações adequadas.

O tipo da variável determina quais comparações fazem sentido.

Um salário, uma cidade e uma data representam coisas diferentes.

Tipo	Exemplo	Pergunta comum	Gráficos comuns
Numérica contínua	renda, temperatura, peso	Como os valores se distribuem?	Histograma, boxplot, scatter
Numérica discreta	número de compras	Quantos eventos ocorreram?	Barras, histograma
Catégorica nominal	cidade, canal, produto	Qual categoria é mais frequente?	Barras
Catégorica ordinal	baixo, médio, alto	Como os níveis se comparam?	Barras ordenadas
Temporal	data, hora, mês	Como algo evolui?	Linha

SEÇÃO 03

Histograma — onde os valores estão concentrados?

? Pergunta

Se eu tiver 1.500 salários, como descubro quais faixas são mais comuns?

Ler 1.500 valores individualmente não ajuda a perceber o formato geral. O histograma agrupa valores próximos em faixas e mostra quantas observações caem em cada faixa. Com isso conseguimos enxergar rapidamente **concentração, simetria, caudas, múltiplos picos e possíveis valores extremos**.

O histograma é especialmente útil no início de uma EDA porque responde uma pergunta básica: "**como esta variável está distribuída?**"

Um histograma divide os valores em **intervalos** e conta quantas observações existem em cada intervalo.


- **Eixo X:** valor da variável.
- **Eixo Y:** quantidade de observações.
- **Cada barra:** uma faixa de valores.

É uma das primeiras ferramentas para entender uma variável numérica.

Escolha uma distribuição simulada:

☒ Normal ☐ Assimétrica ☐ Bimodal

Distribuição normal



O que observar

- Existe apenas um pico ou vários?
- Existe simetria?
- Existe uma cauda muito longa?
- Existem regiões praticamente vazias?
- Existem valores muito afastados?

Ideia principal

O formato da distribuição pode revelar subgrupos, assimetria, outliers e até problemas de qualidade de dados.


Bins — o mesmo dado pode parecer diferente

? Pergunta

O número de barras de um histograma pode mudar nossa interpretação?

Sim. Cada barra representa um intervalo, chamado **bin**. Se usamos poucos bins, valores diferentes são misturados em faixas muito largas e detalhes importantes podem desaparecer. Se usamos bins demais, pequenas variações aleatórias podem parecer padrões relevantes.

Portanto, o número de bins não altera os dados, mas altera a **resolução com que enxergamos a distribuição**. Na prática, é saudável testar mais de uma configuração antes de concluir que existe um pico ou uma separação.



Poucos bins podem **esconder estrutura**.

Bins demais podem produzir **ruído visual**.

Por isso, o histograma deve ser explorado e não tratado como uma representação única e absoluta dos dados.

Curva de densidade — uma visão suavizada


? Pergunta

Existe uma maneira de visualizar o formato da distribuição sem depender tanto das barras?

A curva de densidade, ou KDE, tenta representar a distribuição por meio de uma curva contínua. Ela não mostra contagens exatas como o histograma; mostra **regiões onde os dados estão mais ou menos concentrados**. Picos altos indicam regiões com maior concentração de observações.

Histograma e KDE são complementares: o histograma mantém uma ligação mais direta com a frequência dos dados, enquanto a KDE facilita perceber o formato geral da distribuição.

Histograma + curva de densidade



A curva de densidade pode ser imaginada como uma versão **suavizada do histograma**.

Ela ajuda a visualizar:

- quantidade de picos;
- regiões de maior concentração;
- assimetria;
- possíveis subpopulações.

SEÇÃO 06

Boxplot — resumo da distribuição e valores extremos


? Pergunta

Como resumir rapidamente posição, dispersão e possíveis outliers?

O boxplot comprime uma distribuição inteira em alguns pontos de referência. A linha central representa a **mediana**; a caixa vai do primeiro quartil (Q1) ao terceiro quartil (Q3), concentrando a metade central dos dados. A distância entre Q1 e Q3 é o **IQR**, uma medida de dispersão pouco sensível a valores extremos.

Os pontos que aparecem além dos limites usuais são candidatos a outliers. Isso é um **sinal para investigar**, não uma ordem para excluir a observação.

Distribuição salarial



Q1

5,446

25% dos valores estão abaixo deste ponto.

MEDIANA

6,073

Metade dos valores está abaixo e metade acima.

Q3

6,737

75% dos valores estão abaixo deste ponto.

IQR

1,291

Distância entre Q1 e Q3.

$$IQR = Q_3 - Q_1$$

Uma regra muito utilizada para inspeção de possíveis outliers:

$$Limite superior = Q_3 + 1.5 \times IQR$$

Isso não significa que todo ponto além desse limite está errado.

Significa apenas que ele é incomum em relação à maior parte dos dados.


Visualizando o surgimento de outliers

? Pergunta

O que acontece com nossa distribuição quando valores muito extremos entram na amostra?

Valores extremos podem alterar bastante medidas como média, amplitude e desvio padrão. Na animação, os dados centrais praticamente não mudam, mas novos pontos vão surgindo muito longe da região principal. Isso ajuda a entender por que **uma pequena quantidade de observações pode influenciar fortemente alguns resumos estatísticos**.

Valores extremos entrando progressivamente na amostra



Observe como poucos valores conseguem aumentar muito a amplitude da distribuição, mesmo representando uma parcela mínima da amostra.

💡 Ideia principal

Outliers precisam ser investigados. Excluir automaticamente pontos extremos pode eliminar informações importantes.

SEÇÃO 08


Violin Plot — grupos parecidos podem esconder distribuições diferentes

? Pergunta


Dois departamentos podem ter médias e medianas parecidas e ainda assim serem completamente diferentes?

Sim. Medidas centrais resumem os dados, mas não descrevem todo o formato da distribuição. Dois grupos podem ter medianas próximas e, ainda assim, um deles ser concentrado em torno de um único valor enquanto o outro possui duas populações claramente distintas. O violin plot ajuda porque mostra **onde existe maior densidade de observações ao longo da escala**.

Boxplot



Violin Plot



O **boxplot** resume a distribuição.

O **violin plot** acrescenta uma representação do formato da distribuição.

No segundo departamento podemos perceber dois grandes grupos de salários.

SEÇÃO 09


Gráfico de barras — comparar categorias

? Pergunta

Qual canal possui mais clientes?

Para categorias, normalmente queremos comparar **frequências ou magnitudes**. Como cada categoria é uma classe distinta, barras funcionam melhor do que linhas: o comprimento de cada barra representa diretamente a quantidade associada à categoria. Ordenar as barras também reduz o esforço visual para identificar maiores e menores valores.

Número de clientes por canal



Barras são indicadas quando queremos comparar **magnitudes entre categorias**.

Barras horizontais são especialmente úteis quando os nomes das categorias são longos.

💡 Ideia principal

Ordenar as barras facilita encontrar rapidamente maiores e menores.

SEÇÃO 10


Barras empilhadas — composição dentro de cada grupo

? Pergunta


As regiões possuem apenas quantidades diferentes de clientes ou também possuem composições diferentes de planos?

Barras empilhadas permitem responder duas perguntas diferentes. Em valores absolutos, vemos **quanto cada região representa no total**. Em percentuais, retiramos o efeito do tamanho da região e comparamos apenas **a composição interna**. Uma região pequena pode ter poucos clientes VIP em quantidade, mas ainda possuir uma proporção de VIP maior do que uma região muito maior.

Quantidade absoluta



Composição percentual



Os dois gráficos respondem perguntas diferentes.

Quantidade absoluta

Onde existem mais clientes?

Percentual

Como os clientes daquela região se distribuem entre os planos?

SEÇÃO 11


Pie Chart — quando usar com cautela

? Pergunta


Pizza é sempre uma boa maneira de mostrar proporções?

Não. O cérebro compara comprimentos com mais precisão do que ângulos e áreas. Por isso, pie charts funcionam melhor quando existem **poucas categorias e diferenças grandes**. Quando as fatias são numerosas ou muito parecidas, um gráfico de barras costuma tornar a comparação muito mais clara.

Poucas categorias



Comparação mais precisa



Quanto mais categorias ou quanto menores as diferenças, mais difícil é comparar ângulos de uma pizza. Nesses casos, barras geralmente são melhores.


? Pergunta

Clientes com maior renda parecem gastar mais?

O scatter plot coloca cada observação como um ponto definido por duas variáveis numéricas. Se os pontos formam uma direção crescente, temos indício de associação positiva; se formam uma direção decrescente, associação negativa. Nuvens sem direção clara sugerem associação linear fraca.

O gráfico também permite enxergar **grupos**, **curvaturas** e **outliers** que um único coeficiente de correlação pode esconder.

Renda x gasto mensal



O scatter plot permite investigar:

- direção da relação;

- intensidade aproximada;
- relações não lineares;
- grupos;
- pontos incomuns.

Uma terceira variável pode ser representada pela **cor** e outra pelo **tamanho do ponto**.

SEÇÃO 13


Uma relação não aparece com cinco observações

? Pergunta

Como nosso entendimento muda conforme mais dados ficam disponíveis?

Com poucas observações, padrões aparentes podem surgir apenas por acaso. A animação adiciona pontos em etapas para mostrar como uma relação começa incerta e se torna mais estável conforme a amostra cresce. Isso não quer dizer que amostras grandes garantem conclusões corretas, mas ajuda a entender por que **evidências frágeis não devem ser generalizadas rapidamente**.

Os pontos aparecem progressivamente



Com poucos pontos é perigoso tentar encontrar um padrão.

Conforme a amostra cresce, a estrutura fica mais evidente.


Essa é uma das razões pelas quais conclusões baseadas em amostras muito pequenas devem ser tratadas com cuidado.

? Pergunta

Se duas variáveis aumentam juntas, uma necessariamente causa a outra?

Não. Correlação mede associação, não mecanismo causal. Duas variáveis podem caminhar juntas porque uma causa a outra, porque ocorre o contrário ou porque **uma terceira variável influencia ambas**. No exemplo abaixo, temperatura aumenta tanto o consumo de água quanto o consumo de sorvete. A associação entre água e sorvete existe, mas não significa que um esteja causando diretamente o outro.

Sorvete × consumo de água



Sorvete e água podem apresentar forte correlação.

Isso não significa que:

comprar sorvete faça alguém beber água.

Uma terceira variável — neste exemplo, **temperatura** — influencia ambas.

 Ideia principal

Correlação indica associação. Causalidade exige uma análise muito mais cuidadosa do mecanismo que gerou os dados.

SEÇÃO 15


Gráfico de linha — quando a ordem importa

 Pergunta

Como as vendas evoluíram ao longo do tempo?

Quando a ordem das observações possui significado, especialmente em datas, o gráfico de linha permite seguir a trajetória da variável. Procuramos componentes como **tendência**, **sazonalidade**, variações aleatórias e eventos anormais. Diferentemente de uma variável categórica, aqui conectar os pontos faz sentido porque existe continuidade temporal entre uma observação e a seguinte.

Vendas diárias simuladas



Em séries temporais podemos procurar:

- **tendência;**
- **sazonalidade;**
- **ciclos;**
- **mudanças estruturais;**
- **anomalias.**

Aqui a ordem das observações é essencial. Por isso usamos uma linha.


A série temporal sendo construída

? Pergunta

O padrão de uma série fica evidente imediatamente?

Nem sempre. Uma janela curta pode mostrar apenas ruído ou uma pequena parte de um ciclo. Conforme novos períodos entram na animação, começamos a perceber repetição, direção e estabilidade. Esse exemplo mostra por que o contexto histórico é importante antes de interpretar uma queda ou aumento isolado.

O histórico cresce progressivamente



Conforme novos períodos aparecem, tendência e sazonalidade tornam-se mais fáceis de reconhecer.

Mais histórico não resolve tudo, mas permite enxergar estruturas que seriam invisíveis em uma janela muito curta.


Média móvel — reduzindo o ruído visual

? Pergunta

Como enxergar a tendência quando os dados variam muito diariamente?

A média móvel substitui cada ponto por uma média calculada em uma janela recente. Isso reduz oscilações de curto prazo e facilita perceber a direção geral. A escolha da janela controla o equilíbrio entre **sensibilidade e suavização**: janelas curtas acompanham mudanças rapidamente; janelas longas produzem curvas mais suaves, mas respondem mais devagar.

Série original e médias móveis



A média móvel troca detalhes de curto prazo por uma visão mais suave.


- janela pequena → responde rapidamente;
- janela grande → maior suavização;
- janela muito grande → pode esconder mudanças relevantes.

? Pergunta

Quais variáveis numéricas parecem contar histórias parecidas?

A matriz de correlação resume a associação linear entre vários pares de variáveis. Ela é útil para localizar variáveis muito relacionadas, possíveis redundâncias e relações que merecem investigação. Valores próximos de +1 indicam associação linear positiva; próximos de -1, associação negativa; próximos de zero indicam pouca associação **linear**. Zero não significa necessariamente ausência de qualquer relação.

Matriz de correlação de Pearson



+1

Positiva

As duas tendem a aumentar juntas.

0

Fraca

Pouca associação linear.

-1

Negativa

Uma tende a subir enquanto a outra cai.

Pearson mede principalmente associação linear. Uma relação fortemente não linear pode ter correlação próxima de zero.

SEÇÃO 19


Scatter Matrix — várias relações simultaneamente

? Pergunta

E se quisermos observar várias combinações de variáveis?

A scatter matrix repete o scatter plot para diversos pares de variáveis. Isso permite comparar rapidamente quais combinações apresentam tendência, separação de grupos ou pontos incomuns. É muito útil quando temos poucas variáveis; com muitas colunas, a quantidade de combinações cresce rapidamente e a visualização fica congestionada.

Scatter Matrix



Essa visualização é útil quando temos poucas variáveis.

Com 30 ou 50 variáveis ela rapidamente se torna impraticável.

Nesse caso precisamos selecionar variáveis ou utilizar outras técnicas.


Comparando distribuições entre grupos

? Pergunta


Clientes Básico, Premium e VIP apresentam o mesmo comportamento?

Comparar somente médias pode esconder diferenças importantes. Aqui observamos distribuição, dispersão, caudas e concentração dentro de cada plano. Boxplot, violin e histogramas sobrepostos mostram o mesmo dado por perspectivas diferentes e ajudam a verificar se os grupos realmente possuem comportamentos distintos ou apenas médias diferentes.


Boxplot



Violin Plot



Distribuições sobrepostas



💡 Ideia principal

Não existe 'o melhor gráfico' em qualquer situação. Cada visualização destaca uma característica diferente.

SEÇÃO 21

Outliers — investigar antes de remover

? Pergunta

Um cliente que gasta dez vezes mais que os demais é um erro?

Não necessariamente. Em EDA, um outlier é uma observação incomum em relação ao restante, não uma observação automaticamente inválida. O passo correto é **investigar a origem**: confirmar unidades, regras de negócio, histórico e consistência com outras variáveis. Um grande comprador real pode ser mais importante para o negócio justamente por ser diferente dos demais.

cliente_id	idade	renda_mensal	gasto_mensal	frequencia_compra	plano
1580	52	36204.92	7954.77	9.2	Básico
434	52	34762.02	7714.6	10.7	Básico
1595	65	30697.89	7417.84	11.3	Premium
1875	47	29195.77	7123.71	10.5	Premium
1946	39	37051.72	7106.28	7	Básico
1728	41	28882.05	6835.73	8	Básico
780	49	27673.13	6527.44	7.4	Básico
279	52	29154.17	6453.73	6.3	Básico
825	59	25922.24	6446.9	11	Básico
607	40	27948.8	6354.75	8.6	Básico

Um valor extremo pode representar:

- erro de digitação;
- erro de sensor;
- fraude;
- evento raro;
- cliente excepcional;
- fenômeno legítimo.

O gráfico aponta **onde investigar**.

Ele não decide automaticamente o que deve ser removido.


Dados ausentes — onde estão os vazios?

? Pergunta


Saber apenas que existem valores ausentes é suficiente?

Não. Além da quantidade de valores ausentes, precisamos entender **o padrão da ausência**. Se os valores faltam aleatoriamente, o impacto pode ser diferente de uma situação em que uma coluna fica ausente principalmente para um grupo específico. A própria ausência pode carregar informação sobre processo de coleta, comportamento do cliente ou falhas operacionais.

Percentual de dados ausentes



Padrão de valores ausentes



Perguntas importantes:

- os missing ocorrem aleatoriamente?
- algumas variáveis ficam ausentes juntas?
- determinado grupo possui mais missing?
- o próprio fato de faltar informação pode carregar significado?

SEÇÃO 23


A distribuição geral pode esconder populações diferentes

? Pergunta


Uma distribuição estranha pode ser formada pela mistura de grupos diferentes?

Sim. Quando populações diferentes são misturadas, o gráfico agregado pode parecer assimétrico, multimodal ou muito disperso. Separar os dados por uma variável conhecida pode revelar que cada grupo possui um comportamento bem mais simples. Quando **não conhecemos previamente os grupos**, essa observação naturalmente nos conduz a técnicas de clustering.

Todos os clientes juntos



A mesma distribuição separada por perfil



Quando observamos todos os clientes juntos, enxergamos apenas a mistura.

Quando os grupos são revelados, percebemos que existem comportamentos diferentes.

Isso nos leva a uma pergunta muito importante:

E se não soubéssemos previamente quais são esses grupos?


Essa pergunta será justamente o ponto de partida do treinamento de Clustering.

? Pergunta


A relação observada no conjunto total precisa ser a mesma dentro de cada grupo?

Não. O Paradoxo de Simpson ocorre quando uma tendência observada nos dados agregados muda de intensidade, desaparece ou até se inverte quando analisamos grupos separadamente. A lição prática para EDA é importante: **sempre que existir uma variável de contexto relevante, verifique se a relação permanece dentro dos subgrupos** antes de comunicar uma conclusão geral.

Todos os dados juntos



Os mesmos dados separados por grupo



Ao analisar apenas o conjunto agregado, podemos chegar a uma conclusão.

Ao separar os grupos, a relação pode mudar radicalmente.

Isso acontece porque uma variável de agrupamento pode estar escondendo a verdadeira estrutura dos dados.


💡 Ideia principal

Antes de concluir que duas variáveis se relacionam, verifique se a relação permanece quando analisamos subgrupos importantes.


Uma visualização pode ser tecnicamente correta e ainda assim induzir o leitor a uma interpretação exagerada. Eixos, escalas, ordem das categorias e escolhas de design fazem parte da análise porque alteram a forma como percebemos diferenças.

No exemplo abaixo, os três valores são exatamente os mesmos nos dois gráficos. A única mudança é a escala do eixo Y. Compare a impressão visual produzida pelas duas versões antes de olhar os números.

Eixo cortado



Eixo começando em zero



Os dados são exatamente os mesmos.

No gráfico da esquerda, pequenas diferenças parecem enormes porque o eixo começa em 90.

Outros problemas comuns:

- excesso de cores;
- gráficos 3D sem necessidade;
- categorias fora de ordem;
- dezenas de fatias em uma pizza;
- dupla escala Y;
- omissão de unidades;
- escalas diferentes em gráficos comparados lado a lado.

Qual gráfico escolher?

Quero entender...	Comece por	Pergunta
uma variável numérica	Histograma / KDE	Onde os valores se concentram?
valores extremos	Boxplot	Existem observações muito afastadas?
uma variável categórica	Barras	Quais categorias são mais frequentes?
distribuição entre grupos	Boxplot / Violin	Os grupos possuem comportamento diferente?
duas variáveis numéricas	Scatter	Existe associação ou estrutura?
evolução temporal	Linha	Há tendência, sazonalidade ou eventos?
muitas correlações	Heatmap	Quais variáveis caminham juntas?
muitas relações numéricas	Scatter Matrix	Quais pares apresentam estrutura?
dados ausentes	Barras + matriz de missing	Onde e como os dados estão faltando?

Mini-case — investigando uma base de clientes

Agora vamos juntar os conceitos anteriores em uma pequena investigação. Imagine que esta base acabou de chegar e ainda não sabemos quais padrões existem nela. Em vez de começar por um modelo, seguiremos uma sequência de perguntas: primeiro entendemos cada variável, depois comparamos grupos e relações e, por fim, procuramos estruturas que possam justificar uma técnica de Machine Learning.

Amostra dos dados - 2000 pontos de dados

[illegible]

Para quarta feira

1 — Qual é o perfil de idade?

2 — Existem rendas extremamente altas?

3 — Renda e gasto parecem relacionados?

4 — Os planos possuem comportamentos diferentes?

5 — Quais variáveis parecem relacionadas?

6 — Existe alguma estrutura visual escondida?

SEÇÃO 28

Da exploração para o aprendizado não supervisionado

Durante a EDA descobrimos que nossos clientes parecem ocupar diferentes regiões no espaço.

Agora surge uma nova pergunta:

**Se ninguém nos disser quais são os grupos,
um algoritmo consegue encontrá-los sozinho?**

Na próxima página vamos estudar **Clustering**.

Começaremos entendendo:

1. o que significa similaridade;
2. como calcular distância;
3. por que scaling muda completamente o resultado;
4. como o K-Means encontra centroides;
5. como escolher K;
6. como o algoritmo converge;
7. por que K-Means falha em determinados formatos;
8. Hierarchical Clustering;
9. DBSCAN;
10. HDBSCAN;
11. métricas de avaliação;
12. profiling e interpretação dos grupos.

Fim do treinamento de EDA — a próxima etapa é descobrir automaticamente os grupos que a exploração começou a revelar.