

Clustering — encontrando grupos nos dados

Clustering é uma família de técnicas de **aprendizado não supervisionado**. O algoritmo recebe os dados, mas não recebe uma resposta pronta dizendo a qual grupo cada observação pertence.

A ideia é descobrir estruturas de similaridade: clientes parecidos, produtos parecidos, comportamentos parecidos ou regiões do espaço onde os dados se concentram.

Neste treinamento vamos comparar os principais algoritmos, entender quando cada um funciona bem, como avaliá-los e por que dois algoritmos podem produzir respostas diferentes usando os mesmos dados.

TIPO DE PROBLEMA

Não supervisionado

Não existe uma classe correta fornecida ao algoritmo.

OBJETIVO

Encontrar grupos

Agrupar observações parecidas segundo alguma regra.

PERGUNTA CENTRAL

Quem se parece com quem?

Toda técnica depende de uma ideia de similaridade.

✦ Todos os exemplos desta página usam dados simulados para enxergarmos claramente o comportamento dos algoritmos.

SEÇÃO 01

O que é Clustering?

? Pergunta

Se ninguém me disser previamente quais são os grupos, é possível encontrar uma organização natural nos dados?

Classificação

APRENDIZADO SUPERVISIONADO


Temos uma resposta conhecida. Exemplo: clientes marcados como **churn** ou **não churn**. O modelo aprende usando essas respostas.

Clustering

APRENDIZADO NÃO SUPERVISIONADO

Não existe uma coluna dizendo qual é o grupo correto. O algoritmo procura **estrutura e semelhança** diretamente nos dados.

Os dados chegam sem nenhuma informação de grupo



Visualmente já parece que existem regiões de concentração. Mas o computador não vê “bolinhas formando grupos”. Ele precisa de uma **regra matemática de similaridade**.

Essa é a primeira pergunta antes de escolher qualquer algoritmo.

 Ideia principal

Clustering não cria significado de negócio automaticamente. Ele encontra uma organização matemática dos dados. Depois precisamos interpretar o que essa organização representa.

SEÇÃO 02

O que significa dois pontos serem parecidos?

 Pergunta

Como um algoritmo consegue decidir se dois clientes são semelhantes?


Uma forma comum é transformar cada observação em um ponto.

Imagine duas informações:

- **X = frequência de compras**
- **Y = gasto mensal**

Clientes próximos nesse espaço possuem valores parecidos nessas duas características.

Três clientes representados como pontos



Distância Euclidiana

LINHA RETA

É a distância mais intuitiva: imagine usar uma régua entre dois pontos. É muito usada no K-Means.

Distância Manhattan

CAMINHO EM QUARTEIRÕES

Em vez da diagonal, somamos os deslocamentos horizontal e vertical. O nome vem da ideia de caminhar pelas ruas de uma cidade.

Similaridade do Cosseno

DIREÇÃO É MAIS IMPORTANTE

Muito usada em textos e embeddings. Dois vetores podem ter tamanhos diferentes, mas apontar para direções semelhantes.

$$d(A, B) = \sqrt{(x_B - x_A)^2 + (y_B - y_A)^2}$$

Não precisamos decorar a fórmula. A leitura é simples:

quanto menor a distância, mais próximos os pontos estão segundo as variáveis utilizadas.


Mudar as variáveis ou a medida de distância pode mudar completamente os grupos.

Por que a escala das variáveis importa?


? Pergunta

O que acontece se idade varia entre 20 e 60, mas renda varia entre 2.000 e 50.000?

Antes da padronização



Depois do StandardScaler



Sem scaling, uma diferença de R\$ 10.000 na renda pesa muito mais na distância do que uma diferença de 10 anos de idade, apenas porque os números estão em escalas diferentes.

O `StandardScaler` coloca as variáveis em escalas comparáveis.

$$valor\ padronizado = \frac{valor - média}{desvio\ padrão}$$

Depois disso,  significa aproximadamente perto da média; valores positivos estão acima da média e negativos abaixo da média.

Ideia principal

Em algoritmos baseados em distância, esquecer o scaling pode fazer uma variável dominar a formação dos clusters mesmo sem ser a variável mais importante.

SEÇÃO 04

K-Means — o algoritmo mais conhecido

Pergunta

Como podemos encontrar grupos escolhendo representantes centrais para os dados?

O K-Means tenta dividir os dados em **K grupos**.

Cada grupo possui um **centróide**, que pode ser imaginado como o “centro médio” daquele grupo. O algoritmo repete um ciclo.

1. Escolher K

QUANTOS GRUPOS QUEREMOS?

Se escolhemos $K=3$, o algoritmo tentará produzir exatamente três grupos.

2. Criar centroides

PONTOS DE REFERÊNCIA INICIAIS

O algoritmo começa posicionando três centros iniciais.

3. Agrupar

CADA PONTO PROCURA O CENTRO MAIS PRÓXIMO

Os pontos recebem o cluster do centróide mais próximo.

4. Mover

OS CENTROS SÃO RECALCULADOS

Cada centróide se move para o centro médio dos pontos que recebeu.

Depois os passos 3 e 4 são repetidos até que os centroides praticamente parem de se mover.

Escolha o número de clusters K para a animação:

3



Iteração 1: os centroides se movem para o centro dos pontos que receberam



Como ler a animação

Use **Play** e acompanhe o processo visualmente:

1. **Todos os pontos começam cinza.** Nesse momento ainda não existe nenhum cluster.
2. **Os centroides aparecem como c1 , c2 , c3 ...** Eles são apenas pontos de referência iniciais.
3. **Os dados começam a ganhar cor aos poucos.** Cada ponto recebe a cor do centróide que está mais próximo dele.

4. As linhas finas mostram a ligação dos novos pontos com o centróide escolhido naquele momento.
5. Quando todos os pontos foram distribuídos, **cada centróide é recalculado usando a média dos pontos do seu grupo**.
6. A linha pontilhada mostra **de onde o centróide saiu e para onde ele foi**.
7. Com o centróide na nova posição, as distâncias são calculadas novamente e alguns pontos podem mudar de cluster.
8. O processo continua até os centroides praticamente não se moverem mais.

O ponto importante é perceber que o K-Means não encontra os grupos de uma vez. Ele vai **alternando entre atribuir pontos e reposicionar os centros** até chegar a uma solução estável.

Ideia principal

No K-Means existem duas ações que se repetem: cada ponto escolhe o centróide mais próximo e, depois, cada centróide se move para o centro dos pontos que recebeu.

Quando usar K-Means

CENÁRIO FAVORÁVEL

Excelente primeira opção quando temos muitos dados, variáveis numéricas e esperamos grupos relativamente compactos e bem separados.

Quando evitar

CENÁRIO DESFAVORÁVEL

Pode falhar com formatos muito irregulares, muitos outliers, densidades diferentes ou quando não temos uma boa ideia de quantos clusters existem.


SEÇÃO 05

Como escolher o número de clusters?


Pergunta

Se K-Means exige que escolhamos K, como saber se devemos usar 2, 3, 4 ou 5 grupos?

Elbow Method — Inertia



Silhouette para diferentes valores de K



Inertia

Mede, de forma simplificada, quanto os pontos estão afastados dos centroides de seus próprios clusters. **Menor é melhor**, mas ela quase sempre diminui quando aumentamos K.

Por isso procuramos o **cotovelo**: o ponto a partir do qual adicionar mais clusters traz pouco ganho adicional.

Silhouette

Pergunta: “Este ponto está bem encaixado no próprio cluster ou estaria quase tão confortável em outro?”

- próximo de 1 → bem separado;
- próximo de 0 → fronteira;
- negativo → pode estar no cluster errado.

💡 Ideia principal


Escolher K não deve depender de uma única métrica. Combine métricas, visualização, estabilidade e utilidade para o problema.

K-Means funciona muito bem... até não funcionar


? Pergunta

O que acontece quando os grupos não têm formato aproximadamente circular?

Grupos compactos — K-Means funciona bem



Formato de luas — K-Means corta o espaço



K-Means pensa em **distância até um centro**. Isso funciona para grupos compactos, mas não entende que uma lua curva deve continuar pertencendo ao mesmo cluster. Algoritmos de densidade podem funcionar melhor.

Hierarchical Clustering — formando uma árvore de grupos

? Pergunta


E se começarmos com cada ponto separado e formos juntando os mais parecidos?

No **Agglomerative Hierarchical Clustering**, começamos com cada observação sendo seu próprio grupo.

1. juntamos os dois grupos mais próximos;
2. recalculamos as distâncias;
3. juntamos novamente os mais próximos;
4. continuamos até tudo fazer parte de uma única árvore.

O histórico dessas junções é representado por um **dendrograma**.


Dendrograma — histórico das junções



A altura da junção indica quanto foi necessário aumentar a distância para unir aqueles grupos. Cortar o dendrograma em uma determinada altura equivale a escolher um nível de agrupamento.

Linkage	Ideia simples	Observação
Single	Pontos mais próximos	Pode criar efeito de corrente
Complete	Pontos mais distantes	Tende a grupos compactos
Average	Distância média	Meio-termo
Ward	Grupos internamente compactos	Muito usado com Euclidiana

Resultado do Agglomerative Clustering



Quando usar

BOA ESCOLHA EXPLORATÓRIA

Quando queremos enxergar relações hierárquicas, temos volume moderado de dados e queremos estudar diferentes cortes da estrutura.

Limitação

ESCALABILIDADE

O custo cresce rapidamente com muitos pontos. Não costuma ser a primeira escolha para milhões de observações.

? Pergunta

E se definirmos um cluster como uma região onde existem muitos pontos próximos uns dos outros?

DBSCAN não procura centroides e não precisa saber previamente quantos clusters queremos.

Ele trabalha com:

- **eps**: distância que ainda conta como vizinhança;
- **min_samples**: quantidade mínima de pontos para considerar uma região suficientemente densa.

Pontos que não se conectam a nenhuma região densa podem ser marcados como **ruído**.


Experimente o valor de eps:



Experimente min_samples:



DBSCAN — eps=0.18 | min_samples=5



CLUSTERS ENCONTRADOS

2

O número surge da estrutura dos dados.

PONTOS DE RUÍDO

7

Observações fora de regiões suficientemente densas.

EPS

0.18

Raio usado para procurar vizinhos.

Experimente alterar `eps` :

- **muito pequeno**: muitos pontos viram ruído e grupos fragmentam;
- **muito grande**: regiões diferentes podem acabar conectadas;
- `min_samples` controla o quanto exigimos de densidade.

Quando usar DBSCAN

FORMATO IRREGULAR + RUÍDO

Útil quando esperamos clusters de formatos diferentes de círculos e queremos identificar observações isoladas.

Quando pode ser difícil

DENSIDADES MUITO DIFERENTES

Um único eps pode ser excelente para um cluster denso e ruim para outro mais espalhado.

SEÇÃO 09

HDBSCAN — trabalhando com diferentes densidades


? Pergunta

E se alguns clusters forem muito densos e outros muito espalhados?


HDBSCAN estende a ideia do DBSCAN. Em vez de depender de um único `eps`, analisa a estrutura em vários níveis de densidade e procura grupos que permaneçam **estáveis**.

Isso costuma funcionar melhor quando os clusters têm densidades diferentes.

DBSCAN com um único eps



HDBSCAN



💡 Ideia principal

DBSCAN trabalha com um raio principal. HDBSCAN procura estruturas persistentes em diferentes níveis de densidade, sendo mais flexível em muitos casos reais.

SEÇÃO 10

Gaussian Mixture Models — pertencimento probabilístico

? Pergunta


Todo ponto precisa pertencer 100% a um único cluster?

K-Means faz uma decisão rígida: “este ponto pertence ao cluster 2.”

O Gaussian Mixture Model pode dizer: “75% de chance de cluster 2 e 25% de chance de cluster 1.”

Isso é útil quando existe sobreposição entre grupos.

GMM — tamanho do ponto representa confiança



Pontos nas regiões centrais normalmente apresentam probabilidade alta. Pontos próximos às fronteiras podem ter maior dúvida.

Quando usar

CLUSTERS SOBREPOSTOS

Quando grupos parecem aproximadamente elípticos/gaussianos e queremos uma atribuição probabilística.

Diferença para K-Means

SOFT CLUSTERING

K-Means entrega uma classe rígida. GMM informa quão incerta é a decisão.

K-Medoids — usando um ponto real como representante


? Pergunta

O que acontece se um valor extremo puxar o centro médio do cluster?


K-Means usa a **média** dos pontos para formar o centróide. Valores extremos podem puxar esse centro.

K-Medoids escolhe como representante um **ponto real da própria amostra** que seja central em relação aos outros.

K-Means com valores extremos



K-Medoids



K-Means: o centro pode não ser uma observação real. **K-Medoids:** o representante é obrigatoriamente uma observação existente. Isso tende a ser mais resistente a outliers, porém normalmente com maior custo computacional.

SEÇÃO 12

Como avaliar um clustering?

? Pergunta

Se não existe uma resposta correta conhecida, como podemos dizer se os clusters estão bons?

Em clustering real normalmente não temos `y_true`.

Usamos **métricas internas**, observando duas ideias:

- pontos do mesmo cluster deveriam estar próximos;
- clusters diferentes deveriam estar bem separados.

Métrica	O que tenta medir	Melhor direção
Silhouette	Coesão e separação	Maior
Davies-Bouldin	Semelhança entre clusters	Menor
Calinski-Harabasz	Separação comparada à variação interna	Maior
Inertia	Distância aos centroides	Menor, mas cai quando K aumenta

Algoritmo	Silhouette	Davies-Bouldin	Calinski-Harabasz
K-Means	0.728	0.384	2244.1
Hierárquico	0.728	0.384	2244.1
DBSCAN	0.749	0.361	2489.5
GMM	0.728	0.384	2244.1

💡 Ideia principal

Uma métrica alta não garante que o cluster tenha significado para o negócio. A avaliação final combina qualidade matemática, interpretação e utilidade.

SEÇÃO 13

Comparando os algoritmos

Algoritmo	Precisa nº clusters?	Detecta ruído?	Formatos complexos	Ponto forte
K-Means	Sim	Não	Fraco	Rápido e simples
K-Medoids	Sim	Não	Fraco/Médio	Robusto a outliers
Hierárquico	Não necessariamente	Não diretamente	Médio	Mostra hierarquia
DBSCAN	Não	Sim	Bom	Densidade e ruído
HDBSCAN	Não	Sim	Bom	Densidades variadas
GMM	Sim	Não diretamente	Médio	Probabilidades

Guia prático de escolha

- Muitos dados + grupos compactos: K-Means.
- Quer estrutura hierárquica: Hierarchical/Agglomerative.
- Formato irregular + ruído: DBSCAN.
- Densidades muito diferentes: HDBSCAN.
- Grupos sobrepostos: Gaussian Mixture.
- Outliers preocupam e conjunto não é enorme: K-Medoids.

Isso não é regra absoluta. É um ponto de partida.

O algoritmo termina, mas a análise ainda não

? Pergunta

O que significa receber como resultado Cluster 0, Cluster 1 e Cluster 2?

Sozinhos, esses números não significam nada.

Depois de formar os grupos fazemos **profiling**: comparamos as características dos clusters para entender quem são essas pessoas, produtos, lojas ou comportamentos.

cluster	clientes	idade	renda_mensal	gasto_mensal	frequencia_compra	ticket_medio
0	223	49.1	15513.3	2919	8	376.7
1	316	43.7	7107	782.4	5.1	164.7
2	361	27	4490.4	1533.2	11.1	140.8

Agora os clusters podem ser traduzidos para linguagem de negócio.

Um grupo pode representar clientes:

- mais jovens e frequentes;
- tradicionais e com gasto moderado;
- de alta renda e alto valor.

O nome final deve surgir **depois de observar o perfil**, e não antes.

💡 Ideia principal

O algoritmo cria identificadores. O cientista de dados cria interpretação.

Case final — Segmentação de clientes

Vamos fechar o treinamento percorrendo um fluxo completo, do dado bruto até a interpretação dos clusters.

1 — Nossa base

idade	renda_mensal	gasto_mensal	frequencia_compra	ticket_medio	perfil_latente	cluster
24	3162.99	1395.32	11.2	124.64	Jovem digital	2
27	3785.36	1400.52	8.7	161.15	Jovem digital	2
28	5021.35	1891.23	15.6	121.31	Jovem digital	2
52	12913.85	3101.38	5.8	533.59	Alto valor	0
38	5842.87	758.46	4.9	153.37	Tradicional	1
44	14768.06	2919.44	10.1	289.34	Alto valor	0
41	17762.22	2818.46	8.8	318.94	Alto valor	0
20	3829.84	1721.78	10.9	158.18	Jovem digital	2
37	7090.12	469.8	5.9	79.02	Tradicional	1
55	12662.12	3044.55	8.6	355.49	Alto valor	0

Usaremos cinco variáveis:

- idade;
- renda mensal;
- gasto mensal;
- frequência de compra;
- ticket médio.

Nenhuma informa qual é o grupo do cliente.


2 — Por que padronizar?

Variável	Mínimo	Máximo	Desvio padrão
idade	18	69	11.09
renda_mensal	1800	21482.57	4658.15
gasto_mensal	348.55	3831.09	852.68
frequencia_compra	1	16.4	3.13
ticket_medio	72.09	645.49	110.1


Renda e gasto possuem números muito maiores que idade ou frequência. Sem scaling, essas variáveis dominariam a distância. Por isso usamos `StandardScaler`.

3 — Escolhendo K

Elbow Method




Silhouette por K



Neste conjunto simulado, o maior Silhouette entre os valores avaliados ocorreu em K=3. Isso é uma evidência útil, não uma verdade absoluta.

4 — Resultado do K-Means

Clusters encontrados — Renda × Gasto



O algoritmo usou cinco variáveis, embora este gráfico mostre apenas duas dimensões. Um gráfico 2D é apenas uma projeção do resultado.

5 — Métricas do resultado

SILHOUETTE

0.585

Maior tende a indicar melhor separação e coesão.

DAVIES-BOULDIN

0.588

Menor tende a ser melhor.

CALINSKI-HARABASZ

1847.6


Maior tende a indicar grupos mais separados.

6 — Profiling

cluster_case	idade	renda_mensal	gasto_mensal	frequencia_compra	ticket_medio	clientes
0	49.1	15513.3	2919	8	376.7	223
1	43.7	7107	782.4	5.1	164.7	316
2	27	4490.4	1533.2	11.1	140.8	361

7 — Radar simplificado dos perfis

Perfil relativo dos clusters



Como interpretar o radar:

- valor próximo de 0 → perto da média geral;
- positivo → acima da média;
- negativo → abaixo da média.

O objetivo é entender **como cada cluster se diferencia dos demais**.

8 — Traduzindo clusters para negócio

Cluster	Cientes	Leitura inicial
0	223	renda mensal acima da média e ticket medio acima da média
1	316	frequencia compra abaixo da média e gasto mensal abaixo da média
2	361	idade abaixo da média e frequencia compra acima da média

Ideia principal

A etapa final de clustering não é escolher a melhor métrica. É explicar quem são os grupos, por que eles existem e o que podemos fazer com essa informação.

SEÇÃO 16

O que levar deste treinamento?

1. Clustering depende da definição de similaridade

Os algoritmos não conhecem o significado humano das variáveis. Trabalham com distâncias, densidades, probabilidades e estruturas matemáticas.

2. Scaling pode mudar completamente o resultado

Se uma variável possui escala muito maior, ela pode dominar a distância.

3. Não existe algoritmo universalmente melhor

K-Means, Hierarchical, DBSCAN, HDBSCAN, GMM e K-Medoids enxergam estrutura de maneiras diferentes.

4. Métrica não substitui interpretação

Silhouette, Davies-Bouldin e Calinski-Harabasz ajudam, mas não dizem se o cluster faz sentido para o problema real.

5. Cluster 0 não é uma conclusão

Depois do algoritmo precisamos estudar cada grupo, comparar suas características e transformar o resultado em interpretação útil.

Fim do treinamento de Clustering.