

Regressão — escolha do modelo, diagnóstico e interpretação

Regressão é usada quando queremos explicar ou prever uma variável numérica: preço, custo, tempo, demanda, quantidade de eventos, consumo ou receita.

Neste treinamento veremos que **não existe um único modelo de regressão para todo tipo de target**. Variáveis contínuas, contagens, custos positivos e séries temporais possuem estruturas diferentes.

Vamos estudar OLS, GLMs, regularização, árvores, Random Forest, Gradient Boosting, XGBoost, resíduos, homocedasticidade, normalidade, autocorrelação, multicolinearidade, influência, métricas, cross-validation, tuning, feature importance, SHAP e cases completos.

PERGUNTA CENTRAL

Qual modelo combina com Y?

A natureza da target ajuda a escolher a família do modelo.

DIAGNÓSTICO

Resíduos

Os erros revelam padrões que uma métrica isolada não mostra.

OBJETIVO

Prever + entender

Inferência estatística e previsão são objetivos relacionados, mas diferentes.

? Pergunta

Quando nossa variável alvo é numérica, qualquer algoritmo de regressão serve?

Contínua

VALOR EM UMA ESCALA

Preço, temperatura, gasto, consumo, duração e receita.

Contagem

0, 1, 2, 3...

Número de acidentes, chamadas, sinistros ou compras.
Poisson e Negative Binomial podem ser mais adequados.

Positiva e assimétrica

VALORES MAIORES QUE ZERO

Custos e severidades frequentemente possuem cauda longa. Gamma e Tweedie podem fazer sentido.

💡 Ideia principal

Antes de comparar R^2 , entenda a natureza da variável que está tentando modelar.

SEÇÃO 02

Regressão Linear e mínimos quadrados


A regressão linear tenta representar a média de Y por uma combinação linear das features.

Em uma única feature:

$Y_{\text{previsto}} = \text{intercepto} + \text{inclinação} \times X$

O OLS escolhe os coeficientes que minimizam a soma dos quadrados dos resíduos.

Regressão linear com 45 observações — linhas pontilhadas = resíduos



Cada linha pontilhada é um **resíduo**:

resíduo = observado – previsto

A reta se ajusta buscando reduzir o conjunto desses erros quadráticos.

Inferência e predição não são exatamente a mesma coisa

Inferência

ENTENDER RELAÇÕES

Queremos interpretar coeficientes, intervalos de confiança e efeitos das variáveis.

Predição

PREVER VALORES NOVOS

O foco é generalização e erro em dados não vistos. Um modelo complexo pode prever melhor e ser menos interpretável.

Pressupostos e diagnósticos do OLS

Aspecto	Pergunta prática	Ferramentas
Linearidade	A forma funcional representa a média de Y?	Residual × fitted, RESET
Independência	Os erros são independentes?	Durbin-Watson, Breusch-Godfrey
Homoscedasticidade	A variância do erro é constante?	Breusch-Pagan, White
Normalidade dos resíduos	Os resíduos são aproximadamente normais quando a inferência depende disso?	Q-Q plot, Jarque-Bera
Multicolinearidade	Features carregam informação quase duplicada?	Correlação, VIF
Especificação	Faltam termos importantes?	Ramsey RESET
Observações influentes	Poucos pontos controlam demais o ajuste?	Leverage, Cook's Distance

Normalidade dos resíduos não é uma exigência universal para previsão. Ela é especialmente importante para a inferência clássica em certas condições.

OLS completo: coeficientes, p-valores, AIC e BIC

Coeficiente	Estimativa	Erro padrão	t	p-valor	IC 2.5%	IC 97.5%
Intercept	17.132	2.569	6.669	0.00000	12.091	22.174
x1	2.531	0.033	75.915	0.00000	2.466	2.596
x2	-1.372	0.048	-28.400	0.00000	-1.466	-1.277
x3	4.096	0.131	31.295	0.00000	3.839	4.353

R²

0.893

Variabilidade de Y explicada pelo modelo.

R² AJUSTADO

0.893

Penaliza features pouco úteis.

AIC

7007.0

Menor é preferível entre modelos comparáveis.

BIC

7026.2

Penaliza complexidade mais fortemente.


P-valor não mede importância, tamanho do efeito nem causalidade.

Análise também coeficientes, intervalos de confiança, plausibilidade e performance fora da amostra.

SEÇÃO 06

Análise de resíduos — o gráfico mais importante depois do ajuste

Resíduos × valores ajustados




Em um bom cenário, esperamos uma nuvem sem estrutura evidente ao redor de zero.

Sinais de alerta:

- curva → possível não linearidade;
- funil → possível heterocedasticidade;
- agrupamentos → variável ou segmento não modelado;
- sequência → possível dependência;
- pontos muito distantes → outliers ou observações influentes.

Exemplo de heterocedasticidade — formato de funil



Teste	Estatística	p-valor	H0
Breusch-Pagan	96.093	0.000000	Homoscedasticidade
White	101.389	0.000000	Homoscedasticidade

Se o p-valor for pequeno, há evidência contra a hipótese de variância constante.

Possíveis caminhos:


- revisar a forma funcional;
- transformar Y;
- usar GLM apropriado;
- modelar a variância;
- usar erros-padrão robustos quando o objetivo é inferência.

Coefficiente	Erro padrão clássico	Erro padrão robusto HC3
Intercept	1.1736	0.8075
x	0.0202	0.0218

SEÇÃO 08

Normalidade dos resíduos e Q-Q Plot

Q-Q Plot dos resíduos



JARQUE-BERA P

0.7006

P-valor pequeno sugere desvio da normalidade.

ASSIMETRIA

0.065

Zero indica simetria aproximada.

CURTOSE

2.957

Ajuda a avaliar o peso das caudas.

Em bases grandes, testes de normalidade podem detectar desvios pequenos e pouco importantes.


Por isso combine teste + Q-Q plot + contexto.

SEÇÃO 09

Multicolinearidade — quando features contam quase a mesma história

Feature	VIF
const	36.41
renda	13.58
limite_credito	13.58
idade	1.00

Correlação entre as variáveis




Consequências de multicolinearidade:

- coeficientes instáveis;
- sinais que mudam;
- erros-padrão maiores;
- dificuldade de interpretar efeitos individuais.

Para previsão, regularização como **Ridge** pode ajudar.

Relação não linear sendo forçada por um modelo linear



Ramsey RESET — p-valor: 0.000000


RESET pode sinalizar forma funcional inadequada.

P-valor pequeno não diz qual termo está faltando; apenas indica que a especificação merece revisão.

SEÇÃO 11

Independência dos erros — cuidado com séries temporais

Resíduos ao longo do tempo



DURBIN-WATSON

0.539

Valor perto de 2 sugere ausência de autocorrelação de primeira ordem.

BREUSCH-GODFREY P

0.000000


P-valor pequeno sugere autocorrelação.

Se existe dependência temporal, considere:

- variáveis defasadas;
- modelos específicos de séries temporais;
- GLS;
- erros AR;
- HAC/Newey-West para inferência robusta.

Outliers, leverage e Cook's Distance

Leverage × resíduo studentizado — tamanho representa Cook's Distance




- **Outlier:** Y muito diferente do esperado.
- **High leverage:** combinação incomum de X.
- **Influente:** observação capaz de alterar muito o ajuste.

Não remova automaticamente. Investigue primeiro.

Ridge, Lasso e Elastic Net

Modelo	Ideia	Quando ajuda
OLS	Minimiza erro quadrático.	Relações simples e inferência clássica.
Ridge	Penaliza coeficientes grandes com L2.	Multicolinearidade e muitas features.
Lasso	Penaliza com L1 e pode zerar coeficientes.	Seleção esparsa.
Elastic Net	Combina L1 e L2.	Features correlacionadas e alguma esparsidade.

Ridge — coeficientes encolhem com maior penalização



GLM — Generalized Linear Models

GLMs ampliam a regressão linear permitindo outras distribuições para Y.

Um GLM combina:

- 1. uma **família de distribuição**;
- 2. um **preditor linear**;
- 3. uma **função de ligação**.


Target	Família	Link comum	Exemplo
Contínua aproximadamente simétrica	Gaussian	Identity	Medida contínua
Contagem	Poisson	Log	Número de eventos
Contagem com variância alta	Negative Binomial	Log	Sinistros com overdispersion
Positiva contínua e assimétrica	Gamma	Log	Custo / severidade
Zero + valores positivos contínuos	Tweedie	Log	Custo agregado com muitos zeros

 Ideia principal

A família do GLM deve combinar com a natureza e a variância da target.

Poisson Regression — dados de contagem

Distribuição de uma target de contagem



MÉDIA

2.79

No Poisson, média e variância ficam na mesma ordem.

VARIÂNCIA

5.04

Compare com a média.

DEVIANCE

1895.6

Medida de falta de ajuste relativa ao modelo saturado.

Por que OLS pode ser inadequado para contagens?

- contagem não pode ser negativa;
- é discreta;
- variância costuma depender da média.

O link log do Poisson garante média prevista positiva.

Overdispersion — quando Poisson fica restritivo demais


MÉDIA 2.83 Média da contagem.	VARIÂNCIA 19.70 Variância muito maior é sinal de overdispersion.	VAR/MÉDIA 6.95 Muito acima de 1 merece investigação.
Modelo	AIC	Deviance
Poisson	10416.8	6868.0
Negative Binomial	7505.0	2131.1

Em dados reais, investigue também:

- excesso de zeros;
- exposição;
- dependência temporal;
- zero-inflated models;
- hurdle models.

Gamma Regression — target positiva e assimétrica

Custo positivo com assimetria à direita



AIC

25766.1

Útil para comparar modelos ajustados aos mesmos dados.

DEVIANCE

547.5

Mede falta de ajuste relativa.

Gamma costuma ser apropriada quando Y é:

- contínua;
- estritamente positiva;
- assimétrica à direita;
- com variância crescente com a média.

Tweedie — muitos zeros e valores positivos

Power	Interpretação
0	Gaussian
1	Poisson
$1 < p < 2$	Compound Poisson-Gamma
2	Gamma
3	Inverse Gaussian


Tweedie é muito útil em situações como custo agregado:

- muitos registros com custo zero;
- registros positivos com distribuição contínua e assimétrica.

SEÇÃO 19

Decision Tree Regressor — dividindo o espaço em regiões

Profundidade da árvore × erro



Árvores capturam não linearidade e interações sem precisarmos escrevê-las manualmente.

O risco é o overfitting: uma árvore muito profunda pode memorizar o treino.

SEÇÃO 20

Random Forest, Gradient Boosting e XGBoost

Modelo	Ideia	Ponto forte	Ponto de atenção
Decision Tree	Uma árvore.	Interpretabilidade.	Overfitting.
Random Forest	Muitas árvores independentes e média das previsões.	Robustez e bom baseline tabular.	Modelo maior e menos interpretável.
Gradient Boosting	Árvores sequenciais corrigindo erros anteriores.	Alta capacidade preditiva.	Sensível a hiperparâmetros.
XGBoost	Boosting otimizado com regularização.	Muito forte em dados tabulares.	Biblioteca externa e tuning.
HistGradientBoosting	Boosting eficiente usando histogramas.	Boa escalabilidade.	Menos transparente.

Modelo	MAE	RMSE	R ²	MAPE
Ridge	271.3	337.9	0.601	12.1%
Linear	271.5	337.9	0.601	12.2%
Gradient Boosting	278.9	347.4	0.578	12.5%
XGBoost	279.3	351.0	0.569	12.5%
Random Forest	284.7	355.2	0.559	12.7%
HistGradientBoosting	292.5	360.5	0.546	13.0%
Decision Tree	346.5	442.1	0.317	15.3%

Métricas de regressão


Métrica	Leitura simples	Cuidado
MAE	Erro absoluto médio na unidade original.	Não enfatiza erros grandes como RMSE.
MSE	Erro quadrático médio.	Fica em unidade ao quadrado.
RMSE	Raiz do MSE e volta à unidade original.	Sensível a outliers.
R^2	Variabilidade explicada.	Pode ser negativo fora da amostra.
R^2 ajustado	R^2 penalizado pelo número de features.	Não substitui validação.
MAPE	Erro percentual médio.	Problema perto de zero.
RMSLE	Erro em escala log.	Exige valores não negativos.
Deviance	Métrica natural em vários GLMs.	Depende da família do modelo.

💡 **Ideia principal**

Escolha a métrica com base no custo do erro do problema, não por hábito.

Gráfico previsto × observado


Previsto × observado — Ridge



SEÇÃO 23

Resíduos também importam em Machine Learning

Resíduo × previsto — Ridge




Mesmo sem depender dos testes clássicos do OLS, resíduos ajudam a encontrar:

- regiões em que o modelo piora;
- viés sistemático;
- variância crescente;
- outliers;
- segmentos problemáticos.

Fold	MAE	RMSE	R ²
1	278.0	345.1	0.571
2	309.0	385.9	0.551
3	300.5	375.2	0.519
4	322.2	409.9	0.444
5	295.7	378.7	0.558

Estabilidade entre folds




Método	Como funciona	Quando usar
Grid Search	Testa todas as combinações.	Espaço pequeno.
Random Search	Amostra combinações.	Espaço maior.
Bayesian Optimization	Usa resultados anteriores para orientar novos testes.	Treinos caros.
Optuna	Framework com busca inteligente e pruning.	Projetos robustos.

rank_test_score	RMSE CV	std_test_score	param_n_estimators	param_max_depth	param_min_samples_split	param_min_samples_leaf	param_max_features
1	396.4748	12.0611	250	None	8	1	log2
2	396.8211	14.3281	350	None	4	1	0.7
3	396.8363	12.4779	250	12	12	1	sqrt
4	397.2586	14.383	350	16	2	1	0.7
5	397.5162	12.9122	250	16	2	1	sqrt
6	398.0301	15.0751	250	16	8	2	1.0
7	398.8914	14.1098	120	None	8	2	1.0
8	399.0072	14.3196	350	12	4	4	1.0
9	399.6191	16.0437	250	12	2	1	1.0
10	400.2281	14.4753	180	8	12	2	1.0

Melhor RMSE médio de CV: 396.5

Feature Importance


Feature Importance nativa do Random Forest



SEÇÃO 27

Permutation Importance


Permutation Importance




SEÇÃO 28

SHAP — explicações globais e locais

Importância global por SHAP




Explicação local de uma previsão



SEÇÃO 29

PCA e redução de dimensionalidade

PCA — projeção das features em duas dimensões



PC1

12.5%

Variância capturada pelo primeiro componente.

PC2

12.2%

Variância capturada pelo segundo componente.

TOTAL 2D

24.7%

Variância representada na projeção.

SEÇÃO 30

Guia prático: qual família considerar?

Situação	Modelos para começar
Y contínua e aproximadamente simétrica	OLS / Ridge
Y positiva e muito assimétrica	Gamma GLM / transformação / boosting
Y é contagem	Poisson GLM
Contagem com overdispersion	Negative Binomial
Muitos zeros + positivos contínuos	Tweedie / modelos em duas partes
Relações não lineares em tabular	Random Forest / Gradient Boosting / XGBoost
Multicolinearidade	Ridge / Elastic Net
Objetivo principal é inferência	OLS / GLM bem especificado + diagnósticos

SEÇÃO 31


Antes de dizer que o modelo pode ser usado

Pergunta	Por que importa
A distribuição de Y combina com o modelo?	Família errada prejudica ajuste e interpretação.
Existem previsões impossíveis?	OLS pode gerar negativos para targets que nunca são negativos.
Os resíduos apresentam estrutura?	Padrões indicam especificação incompleta.
Existe heterocedasticidade?	Pode invalidar inferência clássica.
Há autocorrelação?	Dependência viola hipóteses usuais.
Existe multicolinearidade relevante?	Coeficientes podem ficar instáveis.
Há observações muito influentes?	Poucos pontos podem dominar o ajuste.
Treino e teste estão próximos?	Diferença grande sugere overfitting.
O resultado é estável em CV?	Um único split pode enganar.
A métrica representa o custo real?	MAE e RMSE representam custos diferentes.

Case final — previsão de gasto mensal

1. Entender a target
2. Inspeccionar distribuição
3. Criar split
4. Criar baseline
5. Comparar Linear / Ridge / Tree / Forest / Boosting / XGBoost
6. Avaliar MAE, RMSE e R^2
7. Ver previsto × observado
8. Analisar resíduos
9. Cross-validation
10. Tuning
11. Feature Importance / Permutation / SHAP
12. Validar erro e estabilidade para o negócio

Distribuição da target — gasto mensal



RMSE BASELINE

536.1

Prever sempre a média do treino.

RMSE MODELO

350.8

Erro do modelo otimizado.

MAE MODELO

281.2

Erro absoluto médio.

R² MODELO


0.570

Performance fora da amostra.

Real × previsto



Resíduo × previsto



Ideia principal

O modelo final não é apenas o de menor RMSE. Ele precisa ter erro aceitável, estabilidade, resíduos compreensíveis e comportamento plausível.

SEÇÃO 33

Case final — número de eventos

Cenário	Média	Variação	Var/Média
Dados Poisson simulados	2.79	5.04	1.81
Dados com overdispersion	2.83	19.70	6.95

Fluxo para uma target de contagem:

1. confirmar que Y é uma contagem;
2. analisar zeros e distribuição;
3. considerar exposição;
4. comparar média e variância;
5. ajustar Poisson;
6. verificar overdispersion;
7. testar Negative Binomial;
8. investigar excesso de zeros;
9. analisar deviance e resíduos;
10. validar fora da amostra.

	idade	renda	tempo_cliente	frequencia	reclamacoes	engajamento	dias_sem_comprar	desconto	ticket	gasto_mensal
0	44.0256	5889.5871	4.479	9.7647	3	31.1399	56.2033	9.7368	285.2161	1759.8635
1	59.0184	8067.4892	2.9521	11.6541	0	53.3044	12.5716	6.5091	111.069	2032.6101
2	25.7054	8745.4527	5.2578	5.0431	3	85.1442	11.3006	9.7724	141.3341	2131.004
3	31.9779	6302.4764	5.1428	11.8428	0	65.4089	56.6024	18.1807	226.9475	2600.3551
4	72.8491	9229.1765	6.6421	7.8668	1	53.6022	24.3345	10.5275	193.1811	3594.9339
5	38.9959	8341.9617	15.9538	12.7767	0	20.8671	13.7461	5.8058	148.2778	2334.4766
6	21.1991	9905.3233	5.4919	8.0099	1	68.0376	72.1465	0.7075	149.8552	1856.9523
7	35.5919	9348.1729	5.0938	1.8576	2	10.9082	44.3471	21.1819	164.001	2200.3595
8	11.5424	12167.0917	2.3084	10.5478	1	75.5667	27.6361	17.6966	185.6177	3834.2506
9	44.6501	5561.5831	2.0168	6.6695	0	28.7016	36.0094	13.423	265.4497	2347.687

O que levar deste treinamento?

1. Regressão não é sinônimo de OLS

A natureza de Y pode exigir Gaussian, Poisson, Negative Binomial, Gamma, Tweedie ou modelos não paramétricos.

2. Resíduos contam a história que uma métrica esconde

Sempre investigue resíduos, inclusive em Machine Learning.

3. Homoscedasticidade importa para a inferência clássica

Breusch-Pagan e White ajudam a detectar variância não constante.

4. Normalidade não deve ser tratada como ritual

Ela é relevante principalmente para inferência clássica em determinadas condições.

5. Contagens exigem atenção especial

Poisson pode ser restritivo; overdispersion frequentemente leva a Negative Binomial.

6. GLMs permitem alinhar modelo e distribuição da target

Família e link fazem parte da modelagem.

7. Árvores e boosting capturam não linearidade naturalmente

Random Forest, Gradient Boosting e XGBoost são fortes em dados tabulares.

8. Regularização ajuda com muitas features e colinearidade

Ridge, Lasso e Elastic Net controlam complexidade.

9. Métrica deve refletir o problema

MAE, RMSE, R^2 , MAPE, RMSLE e deviance medem aspectos diferentes.

10. Um modelo só está pronto depois da validação fora da amostra

Diagnóstico, cross-validation, resíduos, estabilidade e interpretação precisam concordar com o objetivo real.

Fim do treinamento de Regressão.